

Patrones del Gasto Público Peruano

Minería de Datos Masivos y Flujos de Datos sobre contrataciones del Estado peruano

- Ricardo Amiel Acuña Villogas
- Juan Leibniz Aquino Espinoza
- Camilo Ernesto Soto Cristóbal

Contrataciones Abiertas del Perú, estándar OCDS, publicación 135 del registro de Open Contracting Partnership. Paquetes 2023 a 2025.


Dataset y preguntas de interés

Punto de partida

- 2,98 GB de CSV en 21 tablas por año, 2023 a 2025
- 281.462 procesos crudos, 177.398 tras la limpieza
- Pregunta 1: qué tan concentrado está el gasto en pocos proveedores
- Pregunta 2: qué relación hay entre número de postores y monto
- Pregunta 3: hay apresuramiento del gasto al cierre del ejercicio

Cómo encajan las cinco partes

Visión de conjunto



Lo único que viaja entre partes es la tabla analítica, de modo que son independientes; las líneas discontinuas marcan la pregunta que una parte deja abierta y otra recoge.

Cada decisión de limpieza queda registrada

Parte I · KDD


Paso	Qué hace	Filas afectadas	Quedan
entrada	tabla analitica cruda	0	281.462
duplicados	una fila por ocid, la mas reciente	0	281.462
descarte	monto_pen nulo o no positivo	22.830	258.632
descarte	fecha fuera de 2023 a 2025	81.234	177.398
imputacion	n_postores con la mediana de su metodo	6.655	177.398
marca	monto fuera de [6.37, 17.99] en escala log,...	565	177.398
recorte	n_postores winsorizado al percentil 99,9, t...	263	177.398

El motor de limpieza devuelve una bitácora, de modo que ningún descarte queda escondido en el código.

Dos decisiones cuestan el 37 por ciento de las filas

Parte I · KDD


Filas que sobreviven a cada decisión



Se descartan los montos no positivos, que son campos no publicados, y las convocatorias fuera de la ventana 2023 a 2025.

Diciembre es el máximo en los dos años completos


Parte I · EDA



El patrón se repite en 2023 y 2024, lo que permite atribuirlo al cierre presupuestal y no al ruido de un año.

El uno por ciento de proveedores concentra el 47 por ciento del monto


Parte I · EDA



El coeficiente de Gini es 0,857 sobre un máximo de 1.

El Gini nacional no describe a un mercado regional típico


Parte I · EDA



Solo Pasco y Lima superan el valor nacional, y el resto queda por debajo: la cifra del país está empujada por Lima.

La falta de competencia tiene dos formas distintas


Parte I · EDA



Bajo cincuenta mil soles el 57 por ciento tuvo un solo postor, y en el resto de tramos se estabiliza cerca del 10 por ciento.

MapReduce sobre RDD frente a DataFrames


Parte I · Spark



El mismo resultado, verificado con `exceptAll` en ambos sentidos, cuesta tres veces más en RDD por la serialización hacia Python.

El particionado por año permite descartar directorios


Parte I · Spark



La ejecución adaptativa amortigua casi por completo una mala elección del número de particiones de barajado.

El tamaño del shingle no se optimiza, se fija con un criterio


Parte II · Similitud



Las dos curvas bajan juntas, así que se toma el k más pequeño que deja el fondo de pares no relacionados por debajo de 0,02.

El error baja como uno sobre la raíz de n

Parte II · MinHash




Cuadruplicar las funciones hash solo divide el error entre dos, y con 128 ya queda por debajo del ancho de decisión de LSH.

Las bandas y las filas definen qué se considera parecido

Parte II · LSH

Curva S: el parámetro que decide qué se busca



El umbral teórico marca el cambio de concavidad de la curva, donde la probabilidad vale 1 menos 1 sobre e y no un medio.

Falsos positivos frente a falsos negativos

Parte II · LSH

Configuración	Candidatos	Falsos pos.	Falsos neg.	Recall	% a verificar
b=128, r=1	993.962	993.699	0	1,0000	49,7230
b=64, r=2	171.259	170.997	1	0,9962	8,5670
b=42, r=3	32.337	32.106	32	0,8783	1,6180
b=32, r=4	1.177	1.051	137	0,4791	0,0590
b=25, r=5	139	64	188	0,2852	0,0070
b=21, r=6	59	18	222	0,1559	0,0030
b=16, r=8	24	0	239	0,0913	0,0010

Un falso positivo lo elimina la verificación exacta posterior y es solo trabajo; un falso negativo se pierde para siempre.

Un caso concreto encontrado por el método

Parte II · LSH


Jaccard	Entidad A	Entidad B
1,000	AUTORIDAD NACIONAL DEL AGUA	AUTORIDAD NACIONAL DEL AGUA
1,000	CENTRO NACIONAL DE ABASTECIMIENTO D...	CENTRO NACIONAL DE ABASTECIMIENTO D...
0,963	MUNICIPALIDAD DISTRITAL DE TAMBO DE...	MUNICIPALIDAD DISTRITAL DE SAN BART...
0,934	UNIDAD EJECUTORA 003 GESTION INTEGR...	UNIDAD EJECUTORA 003 GESTION INTEGR...
0,869	COMISION DE PROMOCION DEL PERU PARA...	COMISION DE PROMOCION DEL PERU PARA...

Los pares de la misma entidad son reconvocatorias del mismo objeto, y el de Tambo de Mora con San Bartolo son dos municipalidades distintas que comparten el pliego del programa Vaso de Leche, lo que indica una plantilla reutilizada y no una irregularidad.

El régimen de medición cambia la conclusión

Parte III · ANN


Lo que se pierde en precisión y lo que se gana en tiempo



En lote el índice aproximado no aporta nada, y consulta a consulta HNSW es un orden de magnitud más rápido.

Por qué existen los índices aproximados


Parte III · ANN



La búsqueda exacta crece de forma lineal con la base y HNSW casi no crece, así que la ventaja aparece al escalar.

El filtro de Bloom respeta su tasa teórica

Parte IV · Flujos




Cada orden de magnitud de precisión cuesta unos diez bits más por elemento, y los falsos negativos son imposibles.

Por qué hacen falta Bloom y Count-Min, no uno de los dos

Parte IV · Flujos


Memoria para la misma tarea de pertenencia y la misma tasa de error



Con la misma tasa de error, el Count-Min necesita sesenta y cuatro veces más memoria para responder pertenencia.

DGIM sobre la ventana reciente


Parte IV · Flujos



El peor error observado queda muy por debajo de la cota del cincuenta por ciento que garantizan dos cubos por tamaño.

El tiempo es la tercera dimensión del compromiso

Parte IV · Flujos



Estas estructuras no ahorran tiempo: cambian memoria por tiempo y por un error acotado.

Las cinco estructuras, lado a lado

Parte IV · Flujos


Estructura	Qué pregunta responde	Memoria	Tiempo
Muestreo por clave	métricas por entidad sobre una muestra	proporcional a la fracción de claves	0.93 us
Reservoir sampling	proporciones sobre todo el flujo	k elementos, fija y conocida de antemano	1.10 us
Bloom Filter	apareció antes este proveedor	79.0 KiB para 67,510 claves	7.35 us
Count-Min Sketch	cuántas veces apareció cada ítem	149 KiB	7.74 us
DGIM	cuántos en los últimos N elementos	20 cubos para N=150,000	0.51 us

Ninguna sustituye a otra: responden preguntas distintas sobre el mismo flujo.

La definición de transacción era el problema

Parte V · Reglas


Canastas con al menos dos ítems, por definición de transacción



La canasta natural tiene coocurrencia en el 2 por ciento de los procesos, así que se redefine como lo que una entidad compra en un mes.

Por qué FP-Growth desplazó a A-Priori

Parte V · Reglas



Al bajar el umbral de soporte, A-Priori explota en candidatos y FP-Growth se mantiene plano.

Reglas con soporte, confianza y lift


Parte V · Reglas

Si compra	También compra	Soporte	Confianza	Lift
CONSERVA DE ENTERO DE SAR...	ACEITE VEGETAL COMESTIBLE	0,0042	0,386	50,90
ACEITE VEGETAL COMESTIBLE	CONSERVA DE ENTERO DE SAR...	0,0042	0,550	50,90
ACEITE VEGETAL COMESTIBLE	ARROZ PILADO SUPERIOR	0,0047	0,616	37,85
ARROZ PILADO SUPERIOR	CONSERVA DE ENTERO DE SAR...	0,0054	0,330	30,58
CONSERVA DE ENTERO DE SAR...	ARROZ PILADO SUPERIOR	0,0054	0,498	30,58
SERVICIO DE ALQUILER DE C...	SERVICIO DE ALQUILER DE E...	0,0043	0,705	18,13
SERVICIO DE ALQUILER DE C...	SERVICIO DE ALQUILER DE E...	0,0089	0,604	15,54
HOJUELA DE AVENA, QUINUA...	LECHE EVAPORADA ENTERA X...	0,0160	0,697	8,81

El lift es el criterio de selección: una confianza alta sobre un ítem ya frecuente no dice nada.

Dónde se concentra la falta de competencia

Parte V · Reglas



El suelo de procesos sin competencia no se reparte al azar, aunque parte de lo que aparece es administrativamente esperable.

Qué aportó cada técnica

Parte VI · Discusión

- El EDA y la curva de Lorenz contestan la concentración con un número
- LSH aporta los candidatos de objetos duplicados
- Las reglas contestan dónde se concentra la falta de competencia
- La búsqueda de vecinos aportó poco a las preguntas y mucho al aprendizaje

Qué se benefició de Spark y qué no

Parte VI · Discusión

- Sí: la ingesta, el EDA y el agrupamiento por bandas de LSH
- No: la búsqueda de vecinos, donde un nodo con FAISS es mejor herramienta
- No: la minería de flujos, cuyo recorrido es secuencial y con estado
- Afirmar que todo mejoró con Spark sería falso

Lo que este trabajo no autoriza a concluir

Parte VI · Discusión

- Que dos objetos casi idénticos impliquen fraccionamiento o colusión
- Que una concentración alta implique conducta anticompetitiva
- Que una regla con lift alto implique causalidad
- Que estas cifras sean oficiales: describen el paquete descargado

Entregables

Cierre

- Seis notebooks ejecutados, uno por parte, con sus módulos de apoyo
- Documento con la justificación detallada de cada decisión
- Informe de seis páginas con la propuesta y los hallazgos
- Reporte web interactivo con quince figuras y seis parámetros ajustables en vivo