Proyecto Integrador 2. Avance y propuesta de grafos y recomendación

Ricardo Acuña, Juan Aquino y Camilo Soto. Minería de Datos Masivos, 2026 2. Prof. Heider Sanchez.

Fuente: Contrataciones Abiertas del Perú, estándar OCDS, OECE, licencia CC BY 4.0, paquetes 2023 a 2025.

De qué trata. El proyecto 1 describió el gasto proceso por proceso; este mira **relaciones**: quién le compra a quién y quién compite con quién. Las Partes I y II están cerradas. Para la Parte III y la Parte IV se presenta la propuesta de sistemas de recomendación y de grafos sobre los que se aplicará PageRank, HITS y un grafo KNN. Todo hallazgo se presenta como señal descriptiva para priorizar una revisión, nunca como acusación.

Parte I. Base relacional en Spark

Toda la parte corre en Spark (modo local, 2 GB y 3 hilos). Parte de la tabla limpia del proyecto 1 y produce los tres objetos que piden las demás partes, exportados en Parquet.

1. Resolución de entidades. El mismo proveedor aparece con varios identificadores, sobre todo los consorcios, que reciben un código nuevo por cada inscripción. Primero se unen claves exactas (RUC y nombre normalizado) y luego se hace una pasada difusa con **MinHash y LSH propios** en DataFrames, 10 bandas de 4 filas, porque el MinHashLSH de MLlib no terminaba sobre nombres que comparten la palabra CONSORCIO. Una regla de validación evita fusiones falsas: dos códigos que compiten en el mismo proceso son, por definición, distintos. Resultado: de 211.785 identificadores quedan **167.293 proveedores reales**, y la reducción vive casi entera en los consorcios, 105.881 códigos que son 62.045 consorcios (figura 1, izquierda).

2. Los tres artefactos.

1. **Vectores de características**: 63.204 proveedores y 2.968 entidades, con escala, alcance, dependencia y competencia.
2. **Matrices de interacción**: entidad por proveedor, 2.964 por 63.204 con densidad de 0,06 %, y entidad por familia CUBSO, 2.955 por 368 con 3,3 %. La señal es implícita: número de adjudicaciones y monto, por año.
3. **Grafo de coparticipación de proveedores**: dos proveedores se unen si se presentaron al mismo proceso. Se prefirió al grafo KNN porque aquí la relación existe en el dato. Dos decisiones lo hacen informativo: se descartan procesos con más de 50 participantes, porque uno de 300 genera 44.850 pares que no son relación, y cada coincidencia pesa $1/(n-1)$ (peso de Newman). Se exigen al menos 2 procesos compartidos, el criterio que más reduce aristas según el barrido de sensibilidad. Queda en **70.843 nodos y 2,53 millones de aristas**, con 97,4 % en la componente gigante y grado medio de 71.

3. Particionado. La tabla de hechos se escribe con partitionBy por año, y un filtro por año se vuelve PartitionFilter, sin abrir los otros años. El autojoin por proceso que arma el grafo es el paso más caro; se midió su tiempo según particiones de barajado y se fijaron 8, con ejecución adaptativa activa.

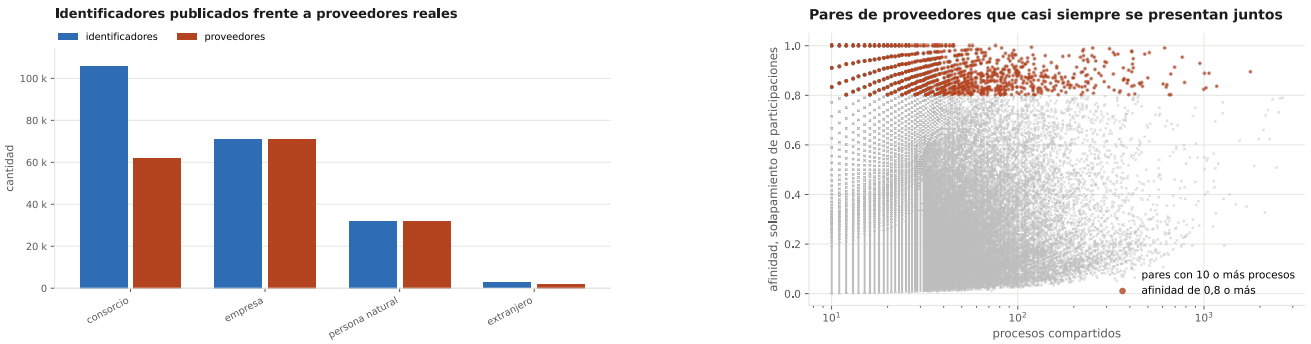


Figura 1: Izquierda: identificadores publicados frente a proveedores reales tras la resolución. Derecha: afinidad de pares con 10 o más procesos compartidos; en rojo, 4.897 pares que coinciden en el 80 % o más de las participaciones del menos activo.

Hallazgos de la Parte I. Solo el 26 % de las relaciones entidad y proveedor de 2025 ya existía en 2023 o 2024: la relación nueva es la norma, lo que motiva la Parte III. Y ordenar pares por conteo de coincidencias solo encuentra a los participantes masivos; medido como **afinidad** (procesos compartidos entre las participaciones del menos activo) aparecen 4.897 pares que se presentan juntos casi siempre, una cola de revisión para el área de competencia.

Parte II. Clustering y detección de anomalías

Población y rasgos. Proveedores con al menos tres adjudicaciones, 12.235, porque con una sola adjudicación las tasas valen 0 o 1 y el algoritmo encuentra esquinas del cubo y no perfiles. Doce rasgos en cuatro grupos: escala (adjudicaciones, monto total y mediano, en logaritmo), alcance (entidades, departamentos, familias), dependencia

y continuidad (cuota del mayor cliente, meses activos) y competencia y rubro (tasa de victoria, postor único, sin concurso, obras). Se estandarizan y se aplica **PCA** en MLlib: la primera componente explica solo el 40 % y hacen falta 6 para el 90 %, así que el comportamiento no se reduce al tamaño.

Métodos, propios y contrastados con bibliotecas.

1. **KMeans++**: el codo del SSE sugiere $k = 5$, pero la silueta es máxima en $k = 4$ (0,383) y se adopta ese; se valida contra KMeans de MLlib.
2. **Jerárquico de Ward** sobre una muestra: cortado en 4 grupos coincide con KMeans con ARI de 0,67, una confirmación por un camino independiente.
3. **DBSCAN**: min_pts igual a 12, el doble de la dimensión, y eps de 1,28 leído en el codo de la curva de distancia al vecino 12; marca 416 proveedores como ruido. Se contrasta con DBSCAN y HDBSCAN de scikit-learn.

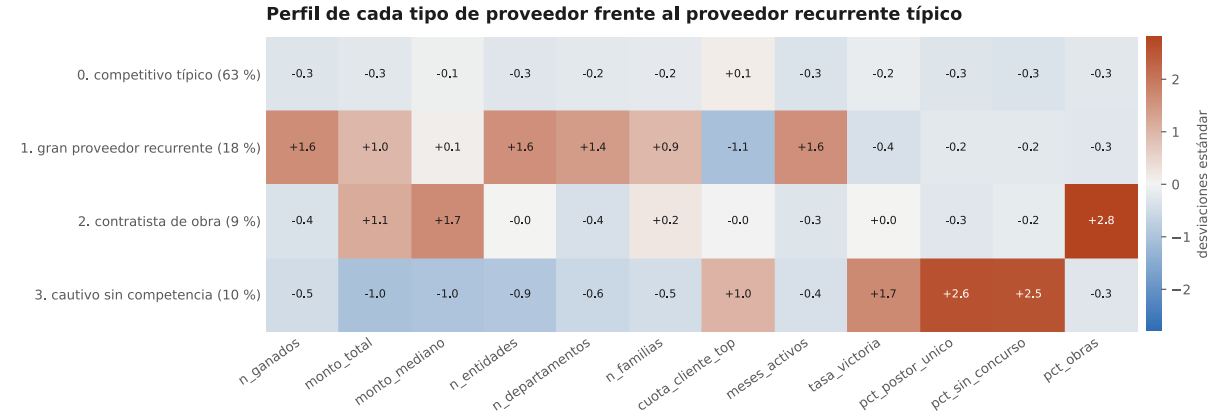


Figura 2: Perfil de cada cluster en desviaciones estándar respecto del proveedor recurrente típico. El cluster 3 combina dependencia de un cliente con ausencia de competencia.

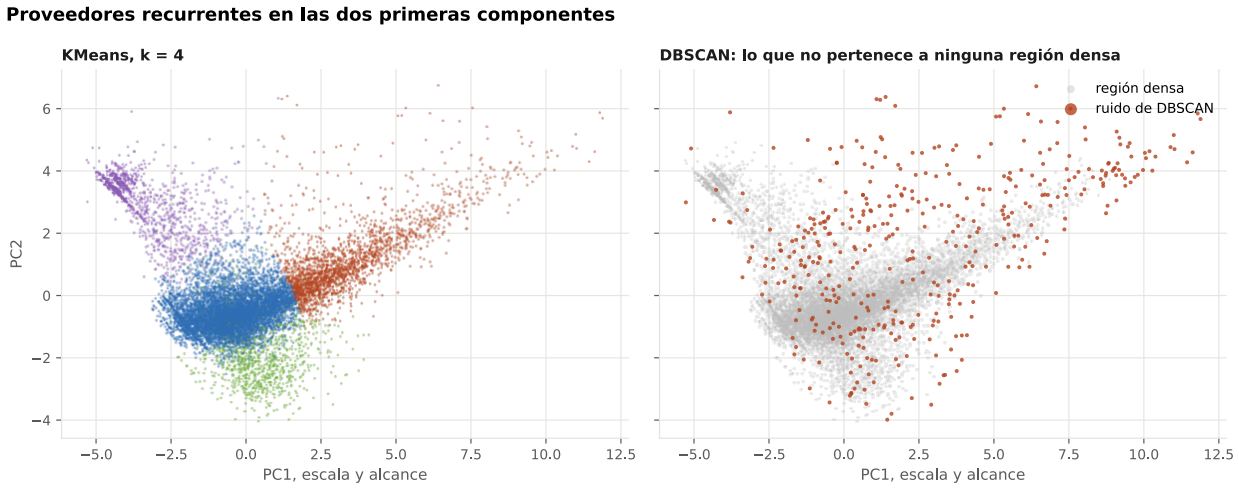


Figura 3: Los mismos proveedores en las dos primeras componentes: KMeans corta el continuo en 4 regiones; DBSCAN deja en rojo lo que no pertenece a ninguna región densa.

Interpretación. Los cuatro perfiles son el competitivo típico (63 %), el gran proveedor recurrente (18 % de proveedores y 49 % del monto), el contratista de obra (9 %) y el **cautivo sin competencia**: 1.285 proveedores que en mediana obtienen el 100 % de su monto de una sola entidad y ganan sin otro postor el 91 % de las veces, S/ 1.645 millones. Las anomalías se definen como ruido de DBSCAN unido a distancia extrema al centroide: 289 proveedores, de los cuales 202 lo son por escala (los grandes proveedores nacionales, rareza esperable) y **87 por competencia o dependencia**, que ganan sin otro postor el 73 % de las veces. Esa segunda cola es la útil para control.

Propuesta para la Parte III. Sistemas de recomendación

Planteamiento. Las entidades son los usuarios, los proveedores son los ítems y la señal es implícita, $\log(1+n)$ con n el número de adjudicaciones. La evaluación es temporal: se entrena con 2023 y 2024 y se mide si el sistema anticipa las **relaciones nuevas de 2025**, con precisión, recall y NDCG en 10 sobre 2.129 entidades. El fin es analítico: medir qué tan esperable es una relación, no sugerir a quién contratar. Proponemos cuatro sistemas, los dos primeros ya prototipados.

1. **R1. Híbrido entidad a proveedor.** Suma de puntajes estandarizados por entidad de cuatro señales: vecindario usuario a usuario con coseno ($k = 50$, elegido en validación), contenido con TF-IDF de familias CUBSO y departamentos del proveedor, ALS implícito de MLlib (rango 48) y popularidad en el departamento. En el prototipo supera a cada señal sola (figura 4): NDCG de 0,087 frente a 0,066 de la popularidad regional, y la ablación muestra que el vecindario es la señal que más aporta.
2. **R2. Sustitutos de proveedor.** Vecinos más cercanos en el espacio de factores de ALS. Sin haber visto las familias, el 15 % de los 10 vecinos comparte la familia principal, frente a 3 % al azar. Uso: para una entidad que depende de un proveedor cautivo de la Parte II, una lista de invitación a cotizar.
3. **R3. Entidad a categoría.** El mismo esquema sobre la matriz entidad por familia CUBSO (3,3 % de densidad, mucho menos dispersa): qué rubros compran entidades parecidas que esta no compra.
4. **R4. PageRank personalizado como quinta señal.** Caminata aleatoria con reinicio desde cada entidad sobre el grafo bipartito G2 de la Parte IV; el puntaje estacionario de cada proveedor es su cercanía a la entidad por caminos de varios pasos. Conecta las Partes III y IV y se evalúa con la misma partición temporal.

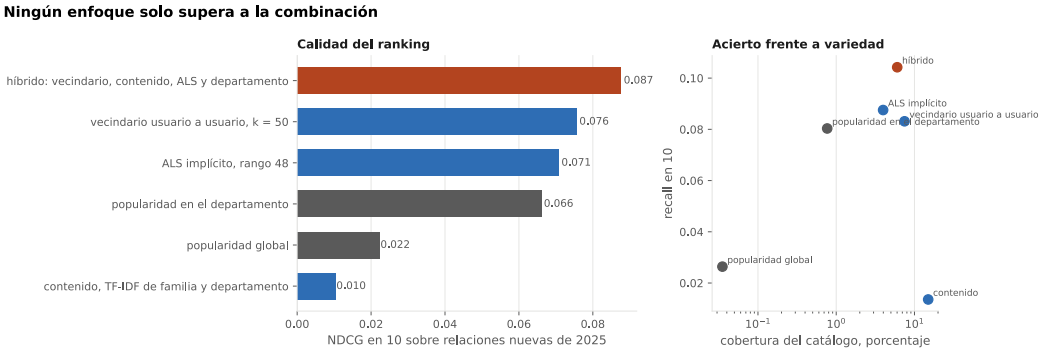


Figura 4: Prototipo de R1 sobre relaciones nuevas de 2025. Ningún enfoque solo supera a la combinación.

Resultado a reportar con honestidad. Que una relación sea improbable para el modelo no predice, por sí solo, menos competencia: postor único de 5,9 % frente a 5,3 %, $p = 0{,}56$. El percentil del modelo se propone para ordenar la revisión dentro de lo que ya es sin concurso o con un solo postor, no como alerta aislada.

Propuesta para la Parte IV. Grafos para PageRank, HITS y grafo KNN

PageRank calcula $r = \beta M r + \frac{1-\beta}{N}\mathbf{1}$, donde M reparte el rango de cada nodo entre sus aristas salientes y el teletransporte con probabilidad $1-\beta$ evita trampas de araña y callejones sin salida. Su resultado depende de qué significa una arista, por eso proponemos cuatro grafos con preguntas distintas (figura 5).

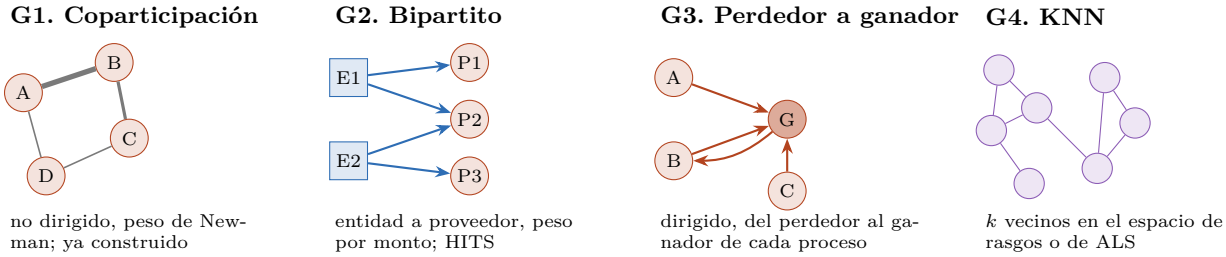


Figura 5: Los cuatro grafos propuestos. Cuadrados: entidades; círculos rojos: proveedores; morados: proveedores como vectores.

1. **G1. Coparticipación de proveedores** (ya construido, 70.843 nodos). Advertencia que guía la propuesta: en un grafo no dirigido, PageRank sin teletransporte es proporcional al grado ponderado, así que aporta poco sobre contar aristas. Aquí se usará para **PageRank personalizado** desde los 4.897 pares afines y para las comunidades de la Parte V.
2. **G2. Bipartito entidad a proveedor** (2.964 entidades y 63.204 proveedores, aristas ponderadas por monto). Es el grafo natural para **HITS**: los hubs son entidades que contratan a proveedores importantes y las authorities, proveedores contratados por entidades importantes. También alimenta R4.
3. **G3. Perdedor a ganador** (dirigido, a construir desde participaciones y adjudicaciones). En cada proceso cada postor perdedor apunta al ganador. Aquí PageRank sí dice algo distinto del grado: un proveedor sube si le gana a quienes ganan. Los ciclos cortos, A le gana a B y B le gana a A en procesos alternados, son el patrón de rotación que conviene cruzar con los pares afines. Los procesos con postor único no generan aristas y quedan fuera por diseño.
4. **G4. Grafo KNN** sobre los 12.235 proveedores recurrentes, con $k = 10$ vecinos en las 6 componentes de PCA o en los factores de ALS, simetrizado por unión. Sirve de entrada al clustering espectral y a Node2Vec (Partes V y VI) y permite medir si los clusters de la Parte II, las comunidades y los embeddings convergen (Parte VII).

Grafo	Algoritmo	Spark o local	Pregunta
G1 coparticipación	PageRank personalizado, comunidades	GraphFrames	¿En qué vecindario de competencia viven los pares afines?
G2 bipartito	HITS, PageRank con reinicio (R4)	local, subgrafo	¿Qué entidades y proveedores son centrales en el mercado?
G3 perdedor a ganador	PageRank con sensibilidad a β	GraphFrames	¿Quién domina a quienes compiten? ¿Hay rotación de ganadores?
G4 KNN	espectral, Node2Vec	local, 12 mil nodos	¿Coinciden clusters, comunidades y embeddings?

Cuadro 1: Resumen de la propuesta de grafos. La sensibilidad al factor de amortiguamiento se medirá con β entre 0,5 y 0,95 comparando el solapamiento de los 100 primeros.